

# Aula 2: Ambientes de Programação

Prof. Mauricio Duarte

### Linguagens...

Linguagens de programação mais utilizadas em Big Data (R e Python);

Coleta de dados, limpeza e integração.





#### Leituras recomendadas...

#### LINGUAGEM R – POR QUE É HORA DE APRENDER?

http://datascienceacademy.com.br/blog/linguagem-r-por-que-e-hora-de-aprender/ (2018)

#### POR QUE CIENTISTAS DE DADOS ESCOLHEM PYTHON? (2019)

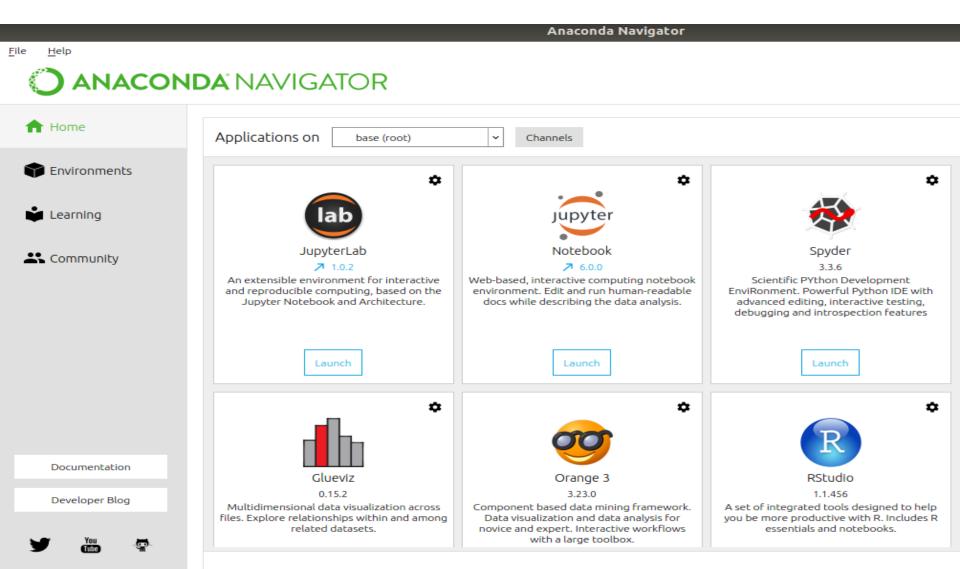
http://www.cienciaedados.com/por-que-cientistas-de-dados-escolhem-python/

#### R OU PYTHON PARA ANÁLISE DE DADOS?

http://www.cienciaedados.com/r-ou-python-para-analise-de-dados/ (2019)

# Gerenciador de aplicações

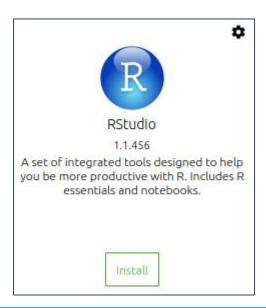
(<a href="https://www.anaconda.com/distribution/">https://www.anaconda.com/distribution/</a>)

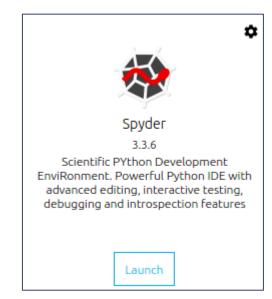


# Ambientes de programação

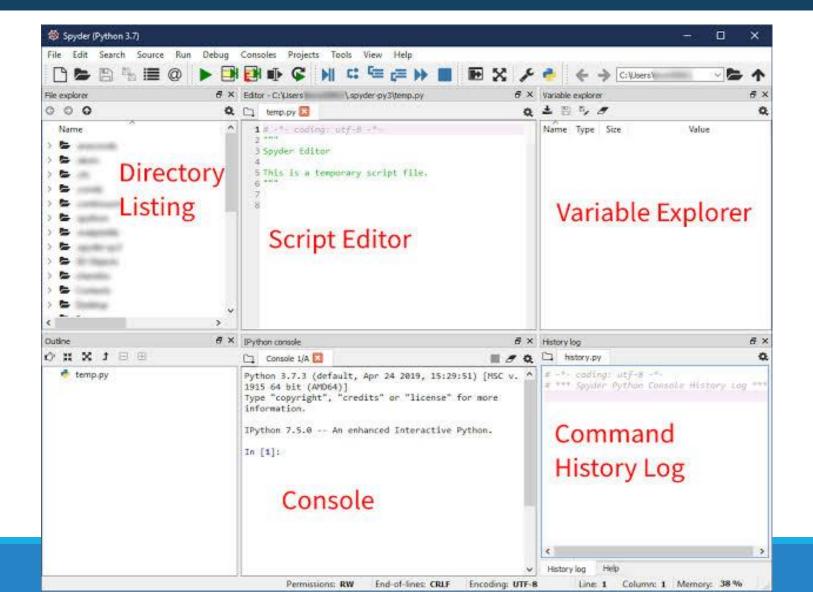
Anaconda - Spyder - Python

Anaconda - Rstudio - R

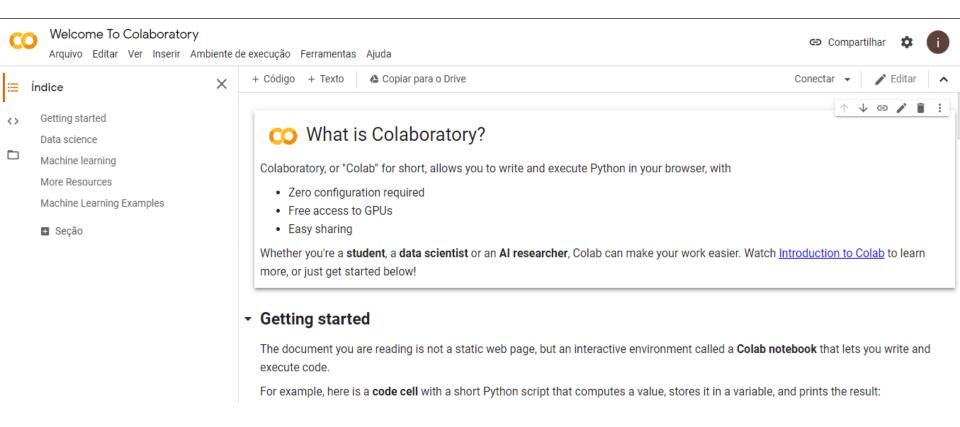




# Ambiente Spyder



# Google Colab



https://www.alura.com.br/artigos/google-colab-o-que-e-e-como-usar

# Pandas

Pandas é uma biblioteca para manipulação e análise de dados, escrita em Python.

Essa é a biblioteca perfeita para iniciar suas análises exploratórias de dados.

Ela permite ler, manipular, agregar e plotar os dados em poucos passos.

https://www.vooo.pro/insights/guia-de-acesso-rapido-ao-pandas/

# Exemplo Pandas no Google Colab

```
import pandas as pd
base_de_dados = pd.read_csv("https://raw.githubusercontent.com/alura-cursos/formacao-data-science/master/movies.csv")
print(base_de_dados)
      movieId
                                                             genres
                     Adventure | Animation | Children | Comedy | Fantasy
                                       Adventure | Children | Fantasy
                1.10
                                                    Comedy Romance
                                              Comedy | Drama | Romance
                                                             Comedy
                                  Action | Animation | Comedy | Fantasy
9737
       193581
                                         Animation | Comedy | Fantasy
       193583
9738
       193585
9739
                                                              Drama
9740
       193587
                                                  Action | Animation
9741
       193609
                                                             Comedy
[9742 rows x 3 columns]
```

## SciKit-sklearn

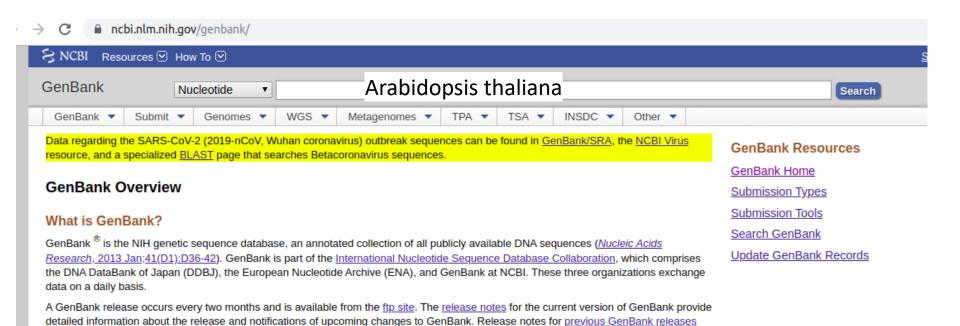
Scikit-sklearn é uma biblioteca Python amplamente usada para projetos que envolvem aprendizado de máquina.

## Bases de Dados em Agricultura

- Genbank (<a href="https://www.ncbi.nlm.nih.gov/genbank/">https://www.ncbi.nlm.nih.gov/genbank/</a>), o banco de dados de sequências genéticas, uma coleção anotada de todas as sequências de DNA disponíveis ao público;
- Base de Dados de Pesquisa Agropecuária

https://www.bdpa.cnptia.embrapa.br/consulta/busca;

### GenBank....



#### Access to GenBank

format.

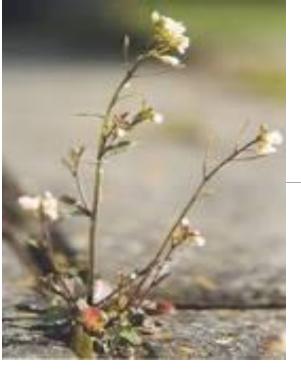
There are several ways to search and retrieve data from GenBank.

- Search GenBank for sequence identifiers and annotations with Entrez Nucleotide.
- Search and align GenBank sequences to a query sequence using <u>BLAST</u> (Basic Local Alignment Search Tool). BLAST searches
  CoreNucleotide, dbEST, and dbGSS independently; see <u>BLAST info</u> for more information about the numerous BLAST databases.

are also available. GenBank growth statistics for both the traditional GenBank divisions and the WGS division are available from each release. GenBank growth statistics for both the traditional GenBank divisions and the WGS division are available from each release.

An annotated sample GenBank record for a Saccharomyces cerevisiae gene demonstrates many of the features of the GenBank flat file

- · Search, link, and download sequences programatically using NCBI e-utilities.
- The ASN.1 and flatfile formats are available at NCBI's anonymous FTP server: <a href="ftp://ftp.ncbi.nlm.nih.gov/ncbi-asn1">ftp://ftp.ncbi.nlm.nih.gov/ncbi-asn1</a> and <a href="ftp://ftp.ncbi.nlm.nih.gov/genbank">ftp://ftp.ncbi.nlm.nih.gov/genbank</a>.



### Arabidopsis thaliana Genoma Organismo Modelo





### Na pesquisa.... 1º. Link...

- Arabidopsis thaliana chromosome 1 sequence
- 30,427,671 bp linear DNA

Accession: CP002684.1 GI: 332189094

<u>Assembly BioProject BioSample Protein PubMed Taxonomy</u>

GenBank FASTA Graphics



٠

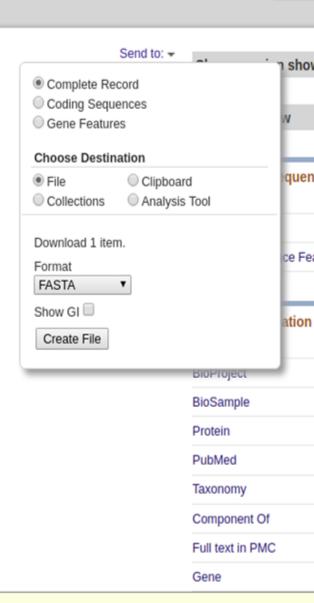
FASTA ▼

#### Arabidopsis thaliana chromosome 1 sequence

Nucleotide

GenBank: CP002684.1
GenBank Graphics

>CP002684.1 Arabidopsis thaliana chromosome 1 sequence CCCTAAACCCTAAACCCTAAACCCTAAACCTCTGAATCCTTAATCCCTAAATCCCTAAATCTTTAAATCC TACATCCATGAATCCCTAAATACCTAATTCCCTAAACCCGAAACCGGTTTCTCTGGTTGAAAATCATTGT GTATATAATGATAATTTTATCGTTTTTATGTAATTGCTTATTGTTGTTGTGTGTAGATTTTTTAAAAATATCA ATTTGTTATATTGGATACAAGCTTTGCTACGATCTACATTTGGGAATGTGAGTCTCTTATTGTAACCTTA GGGTTGGTTTATCTCAAGAATCTTATTAATTGTTTGGACTGTTTATGTTTGGACATTTATTGTCATTCTT ACTCCTTTGTGGAAATGTTTGTTCTATCAATTTATCTTTTGTGGGAAAATTATTTAGTTGTAGGGATGAA GTCTTTCTTCGTTGTTGTTACGCTTGTCATCTCATCTCTCAATGATATGGGATGGTCCTTTAGCATTTAT TCTGAAGTTCTTCTGCTTGATGATTTTATCCTTAGCCAAAAGGATTGGTGGTTTGAAGACACATCATATC AAAAAAGCTATCGCCTCGACGATGCTCTATTTCTATCCTTGTAGCACACATTTTGGCACTCAAAAAAGTA TTTTTAGATGTTTGTTTTGCTTCTTTGAAGTAGTTTCTCTTTGCAAAATTCCTCTTTTTTTAGAGTGATT TAGATATTAGGTAATCTGTAAGTCAACTCATATACAACTCATAATTTAAAATAAAATTATGATCGACACA CGTTTACACATAAAATCTGTAAATCAACTCATATACCCGTTATTCCCACAATCATATGCTTTCTAAAAGC AAAAGTATATGTCAACAATTGGTTATAAATTATTAGAAGTTTTCCACTTATGACTTAAGAACTTGTGAAG ACATACTGAAAAAAGTTGTAATTATTAATGATAGTTCTGTGATTCCTCCATGAATCACATCTGCTTGATT TTTCTTTCATAAATTTATAAGTAATACATTCTTATAAAATGGTCAGAGAAACACCAAAGATCCCGAGATT TCTTCTCACTTACTTTTTTCTATCTATCTAGATTATATAAATGAGATGTTGAATTAGAGGAACCTTTGA ACTTCTCATTGTATATGAGTAAAATCTTTTCTTACAAGGGAAGTCCCCAATTGGTCAACATGTGAAAGCA GGTCCTGAATGTGGCCAAGGTTCCGTCATTTGGAGATACGAAATCAAATCTCCTTTAAGATTTTGTTTTT 



### Atividade prática

### Objetivos:

- 1.) Contar a quantidade de "A"; "C"; "T" e "G"
- 2.) Emitir o percentual médio de cada uma delas.

Python - código para ler um arquivo no formato FASTA e transformá-lo em lista. Disponível em:

https://gist.github.com/marcoscastro/89e8c66703d5067b9b3c

## Leituras Complementares...

#### Trabalhando com Arquivos. Disponível em:

https://panda.ime.usp.br/pensepy/static/pensepy/10-Arquivos/files.html

### Ler arquivos fasta no python e ignorar a primeira linha Disponível em:

https://pt.stackoverflow.com/questions/236391/ler-arquivos-fasta-no-python-e-ignorar-a-primeira-linha/

### Atividade de pesquisa

- Pesquisar como trabalhar com as bibliotecas pandas no uso de funções matemáticas básicas (média, mediana, moda e desvio padrão). Crie um pequeno guia de usuário.
- Faça testes no Colab para entender o funcionamento de tais as funções.